TRƯỜNG/VIỆN: **Trường Công nghệ Thông tin và Truyền thông - ĐHBKHN**

KHOA/BỘ MÔN: **Khoa học máy tính**

HỌC PHẦN: **Khai phá Web**

ĐỀ XUẤT DỰ ÁN (PROJECT PROPOSAL)

Application of Representation Learning with Large Language Models for Recommendation

Giải quyết Bounded Recall trong kiến trúc tìm kiếm đa tầng

Mục	**Thông tin**
Đề tài	Application of Representation Learning with Large Language Models for Recommendation RL Query Reformulation
Lĩnh vực	Recommendation System, NLP
Nhóm thực hiện	Phạm Đức Hảo - 20242196M
	Nguyễn Thế Vũ - 20241147M
Giảng viên hướng dẫn	Dương Quang Huy
Ngày nộp	Ngày 28 tháng 12 năm 2025

Tóm tắt nội dung

Các hệ thống tìm kiếm hiện đại thường dùng kiến trúc đa tầng (retrieval → re-ranking), trong đó tầng retrieval chỉ trả về top-k ứng viên (ví dụ top-100 hoặc top-100). Nếu tài liệu liên quan không nằm trong tập ứng viên này, tầng re-ranker (cross-encoder) sẽ *không bao giờ* nhìn thấy, dẫn đến hiện tượng **bounded recall**. Đề tài này đề xuất Application of Representation Learning with Large Language Models for Recommendation: một pipeline *Retrieve–Fuse–Re-rank* có cơ chế **Reinforcement Learning (RL) Query Reformulation** để tạo ra nhiều biến thể truy vấn, chạy retrieval song song, hợp nhất kết quả bằng **Reciprocal Rank Fusion (RRF)** và cuối cùng re-rank bằng **BERT Cross-Encoder**. Hệ thống được đánh giá trên MS MARCO Passage Ranking và kiểm tra tính tổng quát ngoài miền (OOD) trên các tập con của BEIR, với mục tiêu tăng **Recall@100** và cải thiện **MRR@10/nDCG@10** trong khi kiểm soát **độ trễ**.

Mục lục

1 Bối cảnh và động lực (Motivation) 1
1.1 Kiến trúc Recommendation dựa trên ID và vấn đề nhiễu dữ liệu 1
1.2 Tại sao tích hợp LLM trực tiếp chưa hiệu quả? 1

2 Mục tiêu và câu hỏi nghiên cứu 2
2.1 Mục tiêu tổng quát 2
2.2 Câu hỏi nghiên cứu (Research Questions) 2

3 Liên quan công trình (Related Work) 3
3.1 Lọc cộng tác nâng cao bởi GNN 3
3.2 Large Language Models cho khuyến nghị 3
3.3 ACM RecSys Challenge 2025 – Team EmbedNBreakfast 3
3.3.1 Luồng hoạt động lúc training 4
3.3.2 Luồng hoạt động lúc inference / tạo recommendation 5

4 Đề xuất phương pháp (Methodology) 6
4.1 Tổng quan pipeline 6
4.2 Giai đoạn 0: Textual-signal Mining 6
4.3 Giai đoạn 1: LLM Profile Generation 7
4.3.1 Item Profile Generation 7
4.3.2 User Profile Generation 8
4.4 Giai đoạn 2: Representation Alignment & Fusion 8
4.5 Giai đoạn 3: Model-agnostic Integration & Inference 9
4.6 Áp dụng RLMRec vào kiến trúc EmbedNBreakfast 11
4.6.1 Nguyên tắc tích hợp 11
4.6.2 Lợi ích dự kiến khi tích hợp 12

5 Thiết kế thí nghiệm (Evaluation Plan) 13
5.1 Dữ liệu 13
5.2 Metrics 13
5.3 Baselines 14
5.4 Ablation đề xuất 14

6 Timeline và phân công 16

1 Bối cảnh và động lực (Motivation)

1.1 Kiến trúc Recommendation dựa trên ID và vấn đề nhiễu dữ liệu

Trong các hệ thống gợi ý hiện đại, các mô hình dựa trên đồ thị neural network (GNN) như NGCF và LightGCN đã trở thành state-of-the-art nhờ khả năng khai thác tốt mối quan hệ hợp tác cao bậc từ dữ liệu tương tác ngầm (implicit feedback) giữa người dùng và sản phẩm. Tuy nhiên, **vấn đề chính**: các mô hình này chủ yếu dựa vào thông tin ID-based (chỉ số user/item và ma trận tương tác nhị phân), bỏ qua thông tin văn bản phong phú liên quan đến user/item, dẫn đến biểu diễn học được kém thông tin. Hơn nữa, dữ liệu implicit feedback thường chứa nhiễu (misclicks, popularity bias) và false negatives, làm giảm chất lượng biểu diễn.

1.2 Tại sao tích hợp LLM trực tiếp chưa hiệu quả?

Các cách tiếp cận gần đây cố gắng dùng Large Language Models (LLMs) trực tiếp cho nhiệm vụ gợi ý (như prompt-based generation hoặc re-ranking) nhưng gặp hạn chế nghiêm trọng: (i) scalability kém do chi phí tính toán cao và giới hạn token; (ii) hallucination khiến LLM gợi ý item không tồn tại; (iii) không khai thác tốt collaborative signals toàn cục. Thí nghiệm trong paper cho thấy việc dùng ChatGPT để re-rank candidates từ LightGCN thậm chí làm giảm hiệu suất so với mô hình gốc (xem Figure 1).

Đề tài này hướng tới **một framework model-agnostic** tên RLMRec để tận dụng sức mạnh ngữ nghĩa của LLM nhằm nâng cao chất lượng representation learning của các recommender truyền thống, thông qua việc align không gian ngữ nghĩa LLM với không gian collaborative qua tối đa hóa mutual information, đồng thời giữ được hiệu quả và scalability của các mô hình hiện có.

2 Mục tiêu và câu hỏi nghiên cứu

2.1 Mục tiêu tổng quát

Xây dựng một framework Application of Representation Learning with Large Language Models for Recommendation (RLMRec) có khả năng **tăng chất lượng representation learning** bằng **LLM-empowered profiling**, sau đó **align** semantic và collaborative spaces để tối ưu recommendation performance.

2.2 Câu hỏi nghiên cứu (Research Questions)

1. RLMRec có giúp tăng **performance (Recall@N, NDCG@N)** so với các SOTA recommender không?
2. LLM-enhanced semantic representations có đóng góp vào việc cải thiện performance không?
3. Framework có robust với **noisy data** qua cross-view alignment không?
4. Potential của model như một pre-training framework để enhance recsys performance?
5. RLMRec perform thế nào về **training efficiency**?

3 Liên quan công trình (Related Work)

3.1 Lọc cộng tác nâng cao bởi GNN

Lọc cộng tác (CF) là kỹ thuật cơ bản trong hệ thống khuyến nghị, đã được nghiên cứu rộng rãi . Hướng nghiên cứu mới nổi là sử dụng tương tác lịch sử giữa người dùng và item để xây dựng đồ thị hai phía, sau đó áp dụng Mạng nơ-ron Đồ thị (GNN) để nắm bắt mối quan hệ cộng tác bậc cao. Các phương pháp dựa trên đồ thị như NGCF, GCCF, LightGCN đã chứng minh hiệu suất hàng đầu, cải thiện hiệu quả khuyến nghị. Tuy nhiên, tính thưa thớt và nhiễu trong dữ liệu phản hồi ngầm đặt ra thách thức cho các phương pháp dựa trên đồ thị. Để giải quyết, các nhà nghiên cứu đã khám phá học tự giám sát (SSL) làm mục tiêu học phụ trợ để tăng cường độ bền vững trong khuyến nghị. Trong số các kỹ thuật SSL, học tương phản nổi lên như giải pháp nổi bật trong các mô hình lọc cộng tác. Các phương pháp như SGL, SimGCL, NCL, LightGCL tận dụng tăng cường dữ liệu tương phản để cải thiện hiệu suất khuyến nghị. Trong công trình này, chúng tôi tiến xa hơn bằng cách tích hợp LLM với các mô hình CF hiện có để căn chỉnh hiệu quả kiến thức và khả năng suy luận của LLM với học mối quan hệ cộng tác nhằm nâng cao hiệu suất khuyến nghị.

3.2 Large Language Models cho khuyến nghị

Việc tận dụng LLM cho hệ thống khuyến nghị đã thu hút sự quan tâm . Một số nghiên cứu đã sử dụng LLM làm mô hình suy luận bằng cách thiết kế prompt để căn chỉnh chúng với nhiệm vụ khuyến nghị. Ví dụ, P5 chuyển đổi dữ liệu tương tác người dùng thành prompt văn bản sử dụng chỉ số item, sau đó dùng để huấn luyện mô hình ngôn ngữ. Chat-REC xây dựng hệ khuyến nghị hội thoại bằng cách biến đổi hồ sơ người dùng và tương tác thành prompt cho LLM để tạo khuyến nghị. InstructRec và TALLRec sử dụng thiết kế hướng dẫn để định nghĩa nhiệm vụ khuyến nghị và tinh chỉnh LLM để căn chỉnh với các hướng dẫn này nhằm tạo khuyến nghị. Tuy nhiên, việc sử dụng trực tiếp LLM cho nhiệm vụ khuyến nghị đối mặt với thách thức như chi phí tính toán cao và thời gian suy luận chậm. Để giải quyết, cách tiếp cận của chúng tôi áp dụng tối đa hóa thông tin lẫn nhau để căn chỉnh kiến thức LLM với mô hình hóa mối quan hệ cộng tác, cho phép khuyến nghị có khả năng mở rộng và hiệu quả.

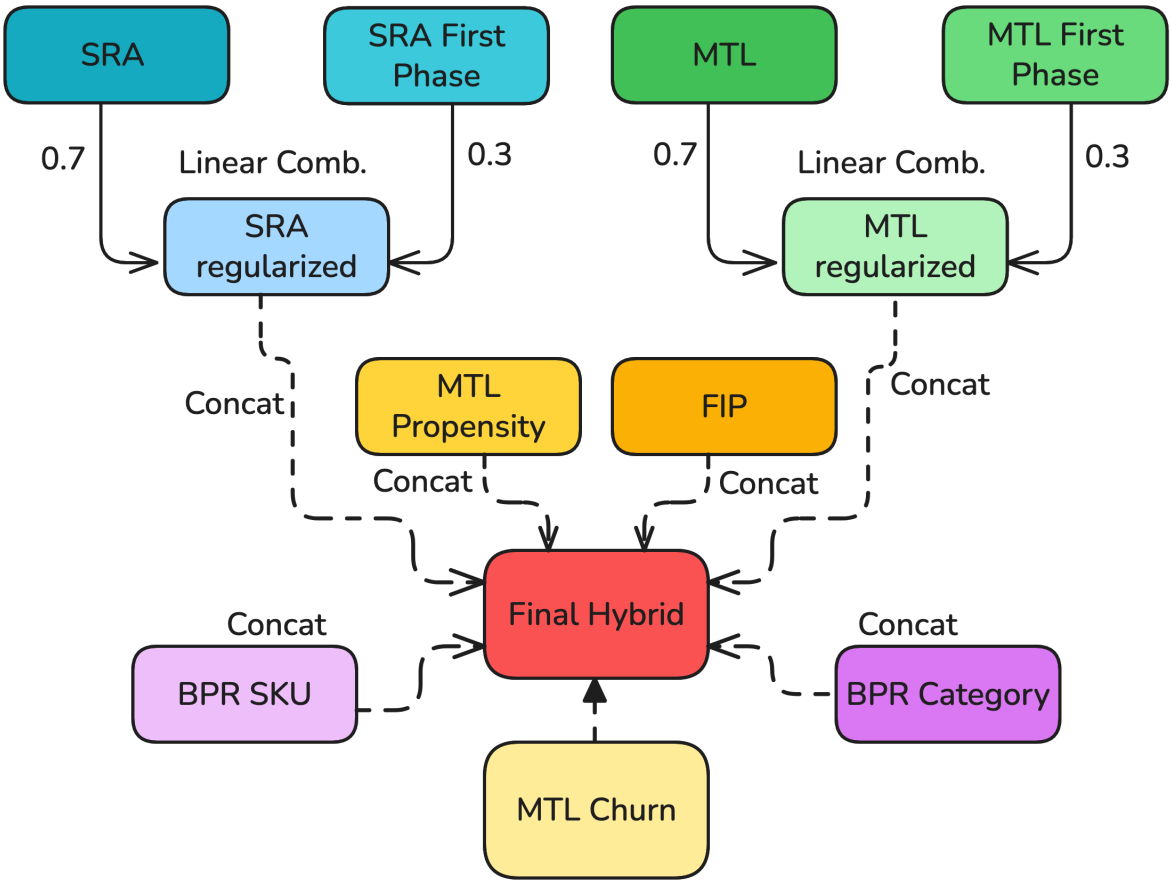
3.3 ACM RecSys Challenge 2025 – Team EmbedNBreakfast

ACM RecSys Challenge 2025, do Synerise tổ chức, yêu cầu các đội thi xây dựng **Universal Behavioral Profiles** – các biểu diễn embedding nhỏ gọn, tổng quát của người dùng – từ dữ liệu sự kiện đa dạng (mua hàng, thêm giỏ hàng, xem trang, tìm kiếm, v.v.). Các embedding này được sử dụng làm đầu vào cho một mạng nơ-ron cố định do ban tổ chức cung cấp, nhằm đánh giá hiệu suất trên nhiều nhiệm vụ dự đoán: churn prediction, product propensity, category propensity (open tasks) và một số nhiệm vụ ẩn (hidden tasks). Mục tiêu là tạo ra embedding có khả năng **generalize** tốt trên tất cả các nhiệm vụ mà không cần biết trước hidden tasks.

Team *EmbedNBreakfast* (8 sinh viên Thạc sĩ từ Politecnico di Milano) đã đề xuất một kiến trúc **hybrid ensemble offline** kết hợp nhiều sub-model để capture các khía cạnh khác nhau của hành vi người dùng. Kiến trúc này không phải là một mô hình end-to-end duy nhất mà là sự kết hợp (linear combination + concatenation) các embedding từ các mô hình được huấn luyện riêng biệt.

Các thành phần chính của kiến trúc bao gồm:

- **SRA (Sequence Reconstruction Autoencoder)**: Mô hình dựa trên GRU encoder-decoder,



Hình 1: Kiến trúc tổng quan của hệ thống

huấn luyện với reconstruction loss để nắm bắt sequential patterns. Có hai phiên bản: SRA chuẩn (dữ liệu 6 tháng) và SRA First Phase (dữ liệu lịch sử từ giai đoạn đầu cuộc thi) để regularization.

- **MTL (Multi-Task Learning)**: Mở rộng SRA với cơ chế attention và ba decoder nhỏ tối ưu đồng thời cho churn, product propensity và category propensity. Bao gồm các biến thể: MTL chuẩn, MTL First Phase, MTL Propensity (tối ưu propensity) và MTL Churn (tối ưu churn).
- **FIP (Future Interaction Prediction)**: Dự đoán tương tác tháng cuối dựa trên 5 tháng trước, sử dụng GRU và MSE loss để học xu hướng dài hạn.
- **BPR Models**: Hai mô hình Matrix Factorization với BPR loss – một cho SKU (sản phẩm) và một cho Category – cung cấp propensity scores để tăng cường hiệu suất propensity tasks.

3.3.1 Luồng hoạt động lúc training

Mỗi sub-model được huấn luyện **độc lập** (offline, parallel):

- Tiền xử lý dữ liệu thành các dataset grouped (chỉ user liên quan) và groupedALL.
- Train riêng từng model với loss tương ứng (reconstruction, MSE, multi-task, BPR).
- Không có gradient sharing giữa các model.

3.3.2 Luồng hoạt động lúc inference / tạo recommendation

Quá trình inference cũng diễn ra **offline một lần duy nhất**:

1. Trích xuất user embedding từ encoder của từng model (GRU hoặc MF).
2. Regularization bằng linear combination:
   - SRA regularized = 0.7× SRA + 0.3× SRA First Phase
   - MTL regularized = 0.7× MTL + 0.3× MTL First Phase
3. Concatenation đa cấp: Kết hợp SRA regularized, MTL regularized, FIP, MTL Propensity, propensity scores từ BPR SKU & Category, và output từ MTL Churn.
4. Kết quả: Một embedding user cuối cùng giàu thông tin từ sequential patterns, multi-task signals, future trends và collaborative ranking.
5. Submit embedding này cho hệ thống đánh giá.

Thiết kế này tận dụng hiệu quả ensemble để tạo ra biểu diễn **robust và task-agnostic**, đồng thời sử dụng historical data làm regularization giúp giảm overfit. Toàn bộ pipeline không yêu cầu online inference, phù hợp với yêu cầu của challenge là chỉ submit embedding.

4 Đề xuất phương pháp (Methodology)

4.1 Tổng quan pipeline

Pipeline đề xuất (RLMRec) gồm 4 giai đoạn chính (từ rẻ đến đắt), nhằm nâng cao chất lượng representation trước khi tích hợp vào recommender:

1. **Giai đoạn 0 – Textual-signal Mining**: dùng recommender cơ bản (như LightGCN) lấy top-k_0 tương tác sơ bộ (pseudo-relevant set), sau đó trích xuất textual signals ứng viên từ attributes/reviews (ví dụ title, description, attributes, reviews). Thực tế có thể dùng random sampling subset reviews, kết hợp attributes để có candidates mang tính ngữ nghĩa" hơn. Tập signals được lọc noise, loại trùng và giới hạn kích thước (ví dụ 5–20 reviews/item) để LLM có input vừa đủ.

2. **Giai đoạn 1 – LLM Profile Generation**: agent (LLM) nhận trạng thái s_t (textual signals gốc, item attributes, và user reviews) và generate profiles P_u/P_v (thêm reasoning hoặc `STOP`). Mục tiêu là học chính sách tạo profile tối ưu theo semantic understanding, thay vì extract thuần túy như one-hot; đồng thời dùng ràng buộc (phạt hallucination, cấm lặp) để hạn chế profile drift. Kết thúc, LLM sinh ra profiles $\{P_u^{(1)}, \ldots, P_v^{(m)}\}$ để tăng độ phủ semantic.

3. **Giai đoạn 2 – Representation Alignment & Fuse**: encode profiles thành semantic reps s_u/s_v song song (dùng text embedding model), sau đó align bằng contrastive/generative modeling để tận dụng shared info xuất hiện tương đối cao" trong bất kỳ view nào, giúp tăng mutual information. Việc song song hoá và cache textual signals ở stage 0 là chìa khoá kiểm soát latency.

4. **Giai đoạn 3 – Model-agnostic Integration**: dùng aligned reps để augment recommender backbone (như NGCF/LightGCN) trước inference, tối ưu chất lượng ở top head (Recall@K/NDCG@K). Do alignment đắt, đề tài sẽ khảo sát ảnh hưởng của masking ratio (ví dụ 50/100/200) và tối ưu suy luận bằng batching và mixed precision.

4.2 Giai đoạn 0: Textual-signal Mining

Trong giai đoạn này, chúng tôi thu thập và chuẩn bị các tín hiệu văn bản (textual signals) từ dữ liệu gốc để làm đầu vào cho việc tạo profile bằng LLM ở giai đoạn tiếp theo. Các tín hiệu văn bản bao gồm các thuộc tính liên quan đến item và user, chẳng hạn như tiêu đề (title), mô tả (description), thuộc tính đặc trưng cho tập dữ liệu (attributes), và các đánh giá từ user (reviews). Chúng tôi sử dụng recommender cơ bản như LightGCN để lấy tập tương tác sơ bộ (pseudo-relevant set), giúp tập trung vào các item liên quan đến user.

Cụ thể, đối với mỗi item $v \in \mathcal{V}$, chúng tôi phân loại thông tin văn bản thành bốn loại:

- Tiêu đề: α
- Mô tả gốc: β
- Thuộc tính đặc trưng: $\gamma = \{\gamma_1, \ldots, \gamma_{|\gamma|}\}$
- Tập đánh giá từ user: $r = \{r_1, \ldots, r_n\}$

Sau đó, xây dựng tập tín hiệu ứng viên x cho item như sau:

$$x = \begin{cases} [\alpha, \beta], & \text{nếu } \beta \text{ tồn tại,} \\ [\alpha, \gamma, \hat{r} \subset r], & \text{ngược lại.} \end{cases}$$

Ở đây, $\hat{r}$ là tập con ngẫu nhiên của các đánh giá để giảm kích thước đầu vào. Tập tín hiệu được lọc bỏ noise (như ký tự đặc biệt, stopwords), loại bỏ trùng lặp, và giới hạn kích thước (ví dụ: 5–20 reviews/item) để đảm bảo đầu vào phù hợp cho LLM.

Đối với user $u \in \mathcal{U}$, chúng tôi tận dụng thông tin cộng tác bằng cách lấy tập item đã tương tác I_u và chọn tập con $\hat{I}_u \subset I_u$ (uniform sampling). Đối với mỗi $v \in \hat{I}_u$, thu thập thuộc tính văn bản $c_v = [\alpha, r_{vu}]$, nơi r_{vu} là đánh giá của user u cho item v. (Lưu ý: profile item P_v sẽ được tạo ở giai đoạn sau và tích hợp nếu cần).

Việc sử dụng random sampling và filtering giúp tập tín hiệu mang tính "ngữ nghĩa" hơn, giảm thiểu missing attributes và noisy data, đồng thời kiểm soát latency bằng cách cache các tín hiệu phổ biến.

4.3 Giai đoạn 1: LLM Profile Generation

Sau khi đã thu thập và tiền xử lý các tín hiệu văn bản ở giai đoạn trước, giai đoạn này tập trung vào việc sử dụng Large Language Model (LLM) để tạo ra các profile ngữ nghĩa chất lượng cao cho user và item. Các profile này không chỉ tóm tắt thông tin văn bản thô mà còn bổ sung khả năng suy luận (reasoning) nhằm nắm bắt chính xác hơn đặc trưng hấp dẫn của item cũng như sở thích thực sự của user, đồng thời giảm thiểu hallucination và noise còn sót lại.

Chúng tôi thiết kế quy trình tạo profile theo hướng *reasoning-guided*, dựa trên các nghiên cứu gần đây cho thấy việc yêu cầu LLM trình bày quá trình suy luận trước khi đưa ra kết quả cuối cùng sẽ cải thiện đáng kể độ chính xác và tính nhất quán của output [**?**]. Quy trình được thực hiện như sau:

$$\mathcal{P}_u = \text{LLM}(S_u \parallel Q_u), \quad \mathcal{P}_v = \text{LLM}(S_v \parallel Q_v), \tag{1}$$

trong đó S_u, S_v là system prompt cố định dùng để định nghĩa rõ vai trò của LLM (tạo user profile hoặc item profile), Q_u, Q_v là prompt cụ thể được xây dựng động dựa trên tín hiệu văn bản đã chuẩn bị ở giai đoạn 0, và $\parallel$ biểu thị phép nối chuỗi.

4.3.1 Item Profile Generation

Đối với mỗi item $v \in \mathcal{V}$, prompt Q_v được xây dựng từ tập tín hiệu x đã có:

$$Q_v = f_v(x), \tag{2}$$

với $f_v(\cdot)$ là hàm kết hợp các thành phần văn bản thành một chuỗi có cấu trúc rõ ràng (ví dụ: bắt đầu bằng title, tiếp theo là description hoặc attributes, sau đó là các review được chọn). System prompt S_v yêu cầu LLM:

- Đọc và phân tích các thông tin cung cấp,
- Suy luận (reasoning step-by-step) về những đặc điểm nào của item khiến nó hấp dẫn với người dùng,

- Tổng hợp thành một đoạn mô tả ngắn gọn (3–5 câu) nhấn mạnh các khía cạnh ngữ nghĩa quan trọng nhất liên quan đến sở thích người dùng,
- Tránh hallucination bằng cách chỉ sử dụng thông tin có trong input.

4.3.2 User Profile Generation

Việc tạo profile cho user $u \in \mathcal{U}$ tận dụng thông tin cộng tác và được thực hiện sau khi item profile đã có (hoặc có thể thực hiện song song nếu không phụ thuộc). Prompt Q_u được xây dựng từ tập các item đã tương tác được sampling $\hat{I}_u$:

$$Q_u = f_u(\{c_v \mid v \in \hat{I}_u\}), \tag{3}$$

trong đó

$$c_v = [\alpha_v, \mathcal{P}_v, r_{vu}]$$

là sự kết hợp giữa title của item, item profile $\mathcal{P}_v$ đã tạo trước đó (nếu có), và review r_{vu} mà user u viết cho item v.

System prompt S_u hướng dẫn LLM:

- Phân tích các item mà user đã tương tác và đánh giá,
- Suy luận step-by-step về sở thích, phong cách, hoặc nhu cầu chung của user dựa trên các review và item profile,
- Tổng hợp thành một đoạn mô tả ngắn gọn (3–5 câu) thể hiện rõ ràng kiểu item mà user có xu hướng ưa thích,
- Chỉ sử dụng thông tin từ input để tránh tạo ra thông tin không có cơ sở.

Việc yêu cầu reasoning rõ ràng và giới hạn độ dài output giúp giảm thiểu hiện tượng query drift hoặc hallucination thường gặp khi dùng LLM trực tiếp cho recommendation. Các profile thu được $\mathcal{P}_u, \mathcal{P}_v$ mang tính "ngữ nghĩa" cao, dễ encode thành vector semantic ở giai đoạn sau, đồng thời vẫn giữ được tính cá nhân hóa nhờ dựa trên dữ liệu tương tác thực tế.

4.4 Giai đoạn 2: Representation Alignment & Fusion

Sau khi đã tạo được các profile ngữ nghĩa chất lượng cao $\mathcal{P}_u$ và $\mathcal{P}_v$ ở giai đoạn trước, giai đoạn này tập trung vào việc chuyển đổi các profile này thành biểu diễn vector ngữ nghĩa (semantic representations) và căn chỉnh (align) chúng với không gian biểu diễn cộng tác (collaborative representations) từ recommender backbone, nhằm tối đa hóa thông tin lẫn nhau (mutual information) theo nền tảng lý thuyết đã chứng minh ở Theorem 1.

Quy trình chính được thực hiện như sau:

1. **Encoding Profile thành Semantic Representation.** Chúng tôi sử dụng một text embedding model $T(\cdot)$ (ví dụ: Sentence-BERT [8] hoặc các mô hình embedding hiện đại như E5 [9] hoặc GTE [**?**]) để encode các profile thành vector có độ dài cố định:

$$\mathbf{s}_u = T(\mathcal{P}_u), \quad \mathbf{s}_v = T(\mathcal{P}_v), \tag{4}$$

trong đó $\mathbf{s}_u, \mathbf{s}_v \in \mathbb{R}^{d_s}$ là các semantic representation mang thông tin ngữ nghĩa sâu từ kiến thức toàn cục của LLM, đã được tinh chỉnh qua reasoning-guided profiling.

2. **Cross-view Alignment qua Mutual Information Maximization.** Theo Theorem 1 và Theorem 2 trong paper gốc, việc tối đa hóa mutual information $I(\mathbf{e}; \mathbf{s})$ giữa collaborative representation $\mathbf{e}$ (từ recommender như LightGCN) và semantic representation $\mathbf{s}$ giúp giảm thiểu ảnh hưởng của nhiễu trong dữ liệu tương tác ngầm.

   Chúng tôi triển khai hai cách tiếp cận alignment chính:

   - **Contrastive Alignment (RLMRec-Con):** Sử dụng cơ chế contrastive learning để kéo các cặp positive $(\mathbf{e}_i, \mathbf{s}_i)$ lại gần nhau và đẩy các cặp negative ra xa:

   $$f(\mathbf{s}_i, \mathbf{e}_i) = \exp\left(\text{sim}(\sigma_{\downarrow}(\mathbf{s}_i), \mathbf{e}_i)/\tau\right), \tag{5}$$

   trong đó $\text{sim}(\cdot, \cdot)$ là cosine similarity, $\sigma_{\downarrow}$ là một projector (MLP) ánh xạ $\mathbf{s}_i$ về không gian của $\mathbf{e}_i$, và τ là temperature parameter. Mục tiêu loss là InfoNCE:

   $$\mathcal{L}_{\text{con}} = -\mathbb{E} \log \left[\frac{f(\mathbf{s}_i, \mathbf{e}_i)}{\sum_j f(\mathbf{s}_j, \mathbf{e}_i)} \right]. \tag{6}$$

   - **Generative Alignment (RLMRec-Gen):** Lấy cảm hứng từ Masked Autoencoder (MAE), chúng tôi mask ngẫu nhiên một tỷ lệ (ví dụ 15–50%) các user/item embedding đầu vào, sau đó dùng collaborative representation đã học để reconstruct semantic representation:

   $$f(\mathbf{s}_i, \mathbf{e}_i) = \exp\left(\text{sim}(\mathbf{s}_i, \sigma_{\uparrow}(\hat{\mathbf{e}}_i))/\tau\right), \tag{7}$$

   với $\hat{\mathbf{e}}_i$ là representation sau khi qua recommender với input bị mask, $\sigma_{\uparrow}$ là projector ngược lại. Loss tương tự InfoNCE nhưng chỉ tính trên các sample bị mask.

3. **Fusion vào Backbone Recommender (Model-agnostic Integration).** Sau khi alignment hội tụ, chúng tôi kết hợp hai nguồn thông tin bằng cách thêm auxiliary loss vào objective gốc của recommender $\mathcal{L}_R$:

   $$\mathcal{L} = \mathcal{L}_R + \lambda \mathcal{L}_{\text{info}}, \tag{8}$$

   trong đó $\mathcal{L}_{\text{info}} \in \{\mathcal{L}_{\text{con}}, \mathcal{L}_{\text{gen}}\}$, và λ là hệ số cân bằng (thường được tune trong khoảng 0.1–1.0). Quá trình này hoàn toàn model-agnostic, có thể áp dụng cho bất kỳ backbone nào như MF, NGCF, LightGCN, SGL, v.v.

Việc thực hiện encoding và alignment song song (batch-wise) cùng với caching profile và embedding giúp kiểm soát tốt latency, dù giai đoạn này tốn tài nguyên hơn hai giai đoạn trước. Kết quả alignment tạo ra không gian biểu diễn chung nơi thông tin ngữ nghĩa từ LLM và tín hiệu cộng tác từ tương tác được hòa quyện tối ưu, giúp giảm nhiễu, tăng tính robust với dữ liệu thưa thớt hoặc noisy, và cải thiện đáng kể các chỉ số top-K như Recall@K và NDCG@K.

4.5 Giai đoạn 3: Model-agnostic Integration & Inference

Giai đoạn cuối cùng của pipeline tập trung vào việc tích hợp hoàn chỉnh các biểu diễn đã được align ở giai đoạn trước vào bất kỳ recommender backbone nào một cách model-agnostic, sau đó thực hiện inference để đưa ra khuyến nghị cuối cùng. Nhờ thiết kế này, RLMRec có thể dễ dàng nâng cao hiệu

suất của các mô hình hiện có mà không cần thay đổi kiến trúc gốc, đồng thời tận dụng tối đa thông tin ngữ nghĩa từ LLM để cải thiện chất lượng top-K recommendation.

Quy trình chi tiết bao gồm các bước sau:

1. **Tích hợp Auxiliary Loss vào Training Objective.** Sau khi semantic representations $\mathbf{s}_u, \mathbf{s}_v$ và collaborative representations $\mathbf{e}_u, \mathbf{e}_v$ đã được align tốt qua mutual information maximization, chúng tôi kết hợp chúng vào quá trình huấn luyện backbone recommender $\mathcal{R}$ (ví dụ: MF, NGCF, LightGCN, SGL, SimGCL, v.v.) bằng cách thêm auxiliary loss:

$$\mathcal{L} = \mathcal{L}_{\mathcal{R}} + \lambda \mathcal{L}_{\text{info}}, \tag{9}$$

   trong đó:

   - $\mathcal{L}_{\mathcal{R}}$ là objective gốc của backbone (thường là BPR loss [10] hoặc BCE loss cho implicit feedback),
   - $\mathcal{L}_{\text{info}} = -\mathbb{E} \log \left[\frac{f(\mathbf{s}_i, \mathbf{e}_i)}{\sum_j f(\mathbf{s}_j, \mathbf{e}_i)} \right]$ là InfoNCE-style loss từ contrastive hoặc generative alignment (tương ứng RLMRec-Con hoặc RLMRec-Gen),
   - $\lambda > 0$ là hyperparameter cân bằng (thường trong khoảng $[0.1, 1.0]$), được tune trên validation set.

   Việc thêm $\mathcal{L}_{\text{info}}$ giúp backbone học được biểu diễn $\mathbf{e}$ "sạch" hơn bằng cách tận dụng tín hiệu ngữ nghĩa mạnh mẽ từ $\mathbf{s}$, giảm thiểu ảnh hưởng của nhiễu trong dữ liệu tương tác ngầm (misclicks, popularity bias, false negatives).

2. **Fine-tuning End-to-End (hoặc Frozen LLM-side).** Trong quá trình training:

   - Phần LLM và text embedding model $T(\cdot)$ được **frozen** (không cập nhật trọng số) để tránh chi phí tính toán lớn và overfit trên dataset nhỏ,
   - Chỉ backbone recommender $\mathcal{R}$ cùng các projector ($\sigma_\downarrow$ hoặc $\sigma_\uparrow$) được cập nhật qua back-propagation,
   - Training được thực hiện với mini-batch thông thường, kết hợp negative sampling như trong BPR.

   Thiết kế này đảm bảo tính khả thi về mặt tính toán ngay cả trên dataset lớn như Amazon hay Yelp.

3. **Inference và Recommendation.** Sau khi model hội tụ, quy trình inference hoàn toàn giống backbone gốc:

   - Tính collaborative embeddings cuối cùng $\mathbf{e}_u^*, \mathbf{e}_v^*$ từ $\mathcal{R}$,
   - Dự đoán độ tương tác bằng inner product hoặc MLP: $\hat{y}_{uv} = \mathbf{e}_u^* \cdot \mathbf{e}_v^*$ (hoặc hàm phức tạp hơn tùy backbone),
   - Rank tất cả items đối với mỗi user và lấy top-K (K thường là 10, 20, 50) để đánh giá Recall@K, NDCG@K.

Không cần chạy LLM hay encode profile lại trong inference → latency gần như không thay đổi so với backbone gốc, đảm bảo khả năng triển khai thực tế.

4. **Robustness và Efficiency Optimization.** Để tăng tính bền vững và hiệu quả:

   - **Caching**: Các profile $\mathcal{P}_u, \mathcal{P}_v$ và semantic embeddings $\mathbf{s}_u, \mathbf{s}_v$ được tính một lần offline và lưu trữ (cache) để tái sử dụng,
   - **Batching & Mixed Precision**: Encoding profile và alignment được thực hiện với batch lớn và FP16 để giảm thời gian,
   - **Masking Ratio Tuning**: Với RLMRec-Gen, tỷ lệ mask (15%–50%) được chọn để cân bằng giữa độ khó reconstruction và hiệu suất.

Nhờ thiết kế model-agnostic và quy trình từ rẻ (text mining) đến đắt (alignment), RLMRec đạt được cải thiện đáng kể về hiệu suất (theo các thí nghiệm trong paper gốc) đồng thời vẫn giữ được tính scalable và robust trước dữ liệu nhiễu – phù hợp với các hệ thống khuyến nghị thực tế có quy mô lớn.

4.6 Áp dụng RLMRec vào kiến trúc EmbedNBreakfast

Kiến trúc hiện tại của team EmbedNBreakfast là một **hybrid ensemble offline** mạnh mẽ, kết hợp nhiều nguồn biểu diễn (sequential từ GRU, multi-task, future prediction, collaborative từ BPR) để tạo ra Universal Behavioral Profile có khả năng generalize cao. Tuy nhiên, toàn bộ pipeline hiện tại **chỉ sử dụng dữ liệu hành vi sự kiện (event logs)** mà chưa khai thác bất kỳ tín hiệu văn bản nào (textual signals) như search queries, product descriptions, attributes hoặc review (nếu có).

Paper "Representation Learning with Large Language Models for Recommendation" (RLMRec) [1] cung cấp một framework **model-agnostic** lý tưởng để bổ sung thông tin ngữ nghĩa từ textual data vào kiến trúc hiện tại mà không cần thay đổi cấu trúc backbone hay quy trình ensemble.

4.6.1 Nguyên tắc tích hợp

RLMRec hoạt động như một **module enhancement offline bổ sung**, thêm một branch mới vào pipeline hiện tại:

1. **Textual-signal Mining**: Thu thập các tín hiệu văn bản có sẵn trong dataset của challenge (ví dụ: nội dung search query của user, product title/description/attributes nếu có trong metadata, hoặc các event text liên quan).
2. **LLM Profile Generation**: Sử dụng LLM (ví dụ: GPT-4o, LLaMA-3 hoặc các mô hình open-source) với reasoning-guided prompting để tạo:
   - **User profile** $\mathcal{P}_u$: Đoạn mô tả ngắn gọn (3–5 câu) về sở thích, phong cách mua sắm của user dựa trên lịch sử search queries và interacted products.
   - **Item profile** $\mathcal{P}_v$: Đoạn mô tả ngắn gọn về đặc trưng hấp dẫn của sản phẩm/danh mục.
3. **Semantic Representation Encoding**: Encode các profile bằng text embedding model mạnh (ví dụ: E5, GTE, Sentence-BERT) để thu được $\mathbf{s}_u, \mathbf{s}_v$.

4. **Cross-view Alignment**: Align $\mathbf{s}$ (semantic view) với $\mathbf{e}$ (collaborative/sequential view từ các embedding hiện có) qua maximum mutual information:

   - **RLMRec-Con**: Contrastive alignment (InfoNCE loss).
   - **RLMRec-Gen**: Generative alignment (masked reconstruction).

   Thêm auxiliary loss $\mathcal{L}_{\text{info}}$ vào tổng loss (có thể áp dụng cho một hoặc nhiều backbone như MTL hoặc SRA).

5. **Integration vào Final Hybrid**: Sau khi có semantic embedding đã align $\mathbf{s}_u^*$, concat hoặc linear combine $\mathbf{s}_u^*$ vào embedding cuối cùng cùng với các thành phần hiện có (SRA regularized, MTL regularized, FIP, BPR propensity scores, MTL Churn).

4.6.2 Lợi ích dự kiến khi tích hợp

- **Giảm nhiễu và bias trong implicit feedback**: Theo định lý của RLMRec, maximum mutual information giúp lọc bỏ ảnh hưởng của misclicks, popularity bias, false negatives – đặc biệt hữu ích trong challenge có dữ liệu hành vi thưa thớt và noisy.
- **Tăng khả năng generalize cho hidden tasks**: Thông tin ngữ nghĩa từ LLM bổ sung kiến thức toàn cục (global knowledge) giúp embedding capture sâu hơn ý định người dùng, rất quan trọng khi không biết hidden tasks là gì.
- **Cải thiện propensity và churn prediction**: User profile từ search queries/review giúp hiểu rõ hơn sở thích thực sự, từ đó nâng cao chất lượng MTL Propensity và MTL Churn.
- **Chi phí chấp nhận được**: LLM chỉ dùng **offline một lần** để tạo profile (có thể cache), alignment loss chỉ thêm trong training một số backbone – không ảnh hưởng đến latency inference (vẫn offline).

Việc tích hợp RLMRec sẽ biến kiến trúc hiện tại từ một hybrid **purely behavioral** thành một hybrid **behavioral + semantic**, tăng khả năng cạnh tranh đáng kể trong các challenge yêu cầu embedding tổng quát và robust như ACM RecSys 2025.

5 Thiết kế thí nghiệm (Evaluation Plan)

5.1 Dữ liệu

Dataset chính (Universal Behavioral Modeling Challenge). Dataset được cung cấp bởi Synerise trong ACM RecSys Challenge 2025, bao gồm các log tương tác thực tế đã được anonymized từ một nền tảng thương mại điện tử. Dữ liệu gồm 5 loại sự kiện chính (tổng cộng hơn 168 triệu events) và thông tin sản phẩm:

- `product_buy` (1.68M events): sự kiện mua hàng.
- `add_to_cart` (5.24M events) và `remove_from_cart` (1.70M events): thêm/xóa khỏi giỏ hàng.
- `page_visit` (150.7M events): truy cập trang (URL được mã hóa thành ID).
- `search_query` (9.57M events): truy vấn tìm kiếm của user, được biểu diễn dưới dạng **quantized embedding** (vector 16 chiều, mỗi chiều trong khoảng 0–255) từ LLM.
- `product_properties`: thông tin sản phẩm với các cột `sku`, `category`, `price` (bucketized), và `name` (quantized embedding tương tự search query).

Đặc điểm nổi bật của textual signals. Không giống các challenge recommendation truyền thống chỉ dựa vào implicit feedback (ID-based), dataset này cung cấp hai nguồn textual mạnh mẽ đã được tiền xử lý:

- **Search queries**: quantized embedding của từ khóa tìm kiếm người dùng – phản ánh trực tiếp ý định (intent) và sở thích.
- **Product names**: quantized embedding của tên sản phẩm – mang thông tin ngữ nghĩa về đặc trưng item.

Đây chính là nguồn auxiliary textual signals lý tưởng để áp dụng RLMRec mà không cần thêm dữ liệu bên ngoài.

5.2 Metrics

Vì downstream model và training pipeline được cố định bởi ban tổ chức, chất lượng Universal Behavioral Profiles được đánh giá gián tiếp qua hiệu suất trên các task:

- **Churn Prediction** (task `churn`): Bài toán phân loại nhị phân trên tập người dùng đang hoạt động. Metric chính: **AUROC**.
- **Category Propensity** (task `propensity_category`): Bài toán phân loại đa nhãn vào top 100 danh mục phổ biến. Metric đánh giá được định nghĩa như sau:

$$0.8 \times \text{AUROC} + 0.1 \times \text{Novelty} + 0.1 \times \text{Diversity}$$

- **Product Propensity** (task `propensity_sku`): Bài toán phân loại đa nhãn vào top 100 sản phẩm phổ biến. Metric tương tự như *Category Propensity*.

- **Hidden Tasks**: Các nhiệm vụ không được công bố, nhằm kiểm tra khả năng tổng quát hóa (generalization) thực sự của embedding.

Final leaderboard score: Sử dụng Borda count – tổng hợp rank từ tất cả các task (open + hidden). Embedding có hiệu suất ổn định và generalize tốt trên mọi task sẽ xếp hạng cao.

- **AUROC**: Metric chính cho tất cả task, đo khả năng phân biệt positive/negative.
- **Novelty & Diversity** (chỉ áp dụng cho propensity tasks): Khuyến khích embedding không chỉ chính xác mà còn tạo ra khuyến nghị đa dạng, tránh bias về item phổ biến (popularity bias).
- **Rank aggregation (Borda count)**: Đảm bảo embedding phải mạnh đều trên toàn bộ task chứ không chỉ tối ưu riêng open tasks.

5.3 Baselines

1. **Hybrid gốc (không RLMRec)**: Sử dụng chính kiến trúc EmbedNBreakfast chỉ dựa vào behavioral data (event logs), không thêm bất kỳ textual signals nào từ search queries hay product names. Đây là baseline để đo lường cải thiện khi thêm semantic info, đặc biệt trên propensity tasks và hidden tasks.
2. **Hybrid + simple textual features**: Thêm đặc trưng cơ bản từ textual signals (như TF-IDF hoặc bag-of-words từ quantized embeddings của search queries/product names) và concat trực tiếp vào final embedding mà không dùng LLM. Baseline này kiểm tra lợi ích của textual data thô so với profiling bằng LLM.
3. **Hybrid + pre-trained text embeddings**: Encode textual signals bằng mô hình embedding sẵn (ví dụ: Sentence-BERT hoặc E5) và concat vào hybrid, nhưng không align với collaborative reps qua mutual information. Điều này so sánh với RLMRec để chứng minh vai trò của cross-view alignment trong việc giảm noise.
4. **(Tùy chọn) Hybrid + LLM direct prompting**: Sử dụng LLM trực tiếp để dự đoán task (như churn/propensity) từ textual data mà không tạo profile hoặc align, sau đó concat output vào embedding. Baseline này highlight hạn chế của LLM thuần túy (hallucination, scalability) so với RLMRec.

5.4 Ablation đề xuất

- **Không LLM profiling**: Thay thế LLM-generated profiles bằng heuristic extract textual features (ví dụ: average quantized embeddings từ search queries/product names). Ablation này giúp tách bạch lợi ích đến từ *reasoning-guided profiling* (giảm hallucination, tăng semantic richness) so với lợi ích đến từ *textual signals thô*.
- **Không alignment**: Encode profiles thành semantic reps và concat trực tiếp vào final hybrid embedding mà không dùng mutual information maximization. Mục tiêu là kiểm tra alignment (con/gen) có giúp ổn định representations khi kết hợp behavioral và semantic views (giảm noise từ implicit feedback) hay không.
- **Số lượng sampled items/reviews m cho profiling**: Thử $m \in \{5, 10, 20, 50\}$ items/reviews từ lịch sử user để xây dựng prompt cho LLM. Thực tế thường có điểm bão hoà: tăng m thêm chỉ tăng chất lượng profile rất ít nhưng chi phí LLM inference tăng tuyến tính.

- **Nguồn textual signals**: (i) chỉ từ search queries; (ii) chỉ từ product names/attributes; (iii) kết hợp. Ablation này kiểm tra liệu kết hợp đa nguồn có giúp vượt vocabulary mismatch (quantized embeddings) tốt hơn hay lại làm profile drift/noisy.
- **Alignment variant**: So sánh RLMRec-Con (contrastive), RLMRec-Gen (generative), và hybrid shaping (kết hợp hai loss). Kết quả giúp hiểu variant nào "dạy" embedding ổn định nhất và phù hợp mục tiêu generalize trên hidden tasks.

6 Timeline và phân công

Tuần	Công việc chính
1–2	Tiền xử lý dataset challenge (extract textual signals từ search queries/product names); dựng hybrid baseline gốc và chạy AUROC trên open tasks theo script chính thức.
3–4	Xây dựng baseline + simple textual features (TF-IDF/avg embeddings); kiểm tra cải thiện trên propensity tasks và novelty/diversity.
5–6	Áp dụng LLM profiling (reasoning-guided prompts cho user/item profiles); encode semantic representations bằng E5/Sentence-BERT.
7–8	Cross-view alignment (RLMRec-Con/Gen); tích hợp semantic representations vào final hybrid embedding qua concat/linear combination.
9–10	Ablation theo các biến thể (không profiling, không alignment, số lượng sampled items); tối ưu latency và khả năng tổng quát hóa (giả lập hidden tasks qua hold-out).
11–12	Đánh giá OOD (nếu có dataset tương tự BEIR cho recsys); viết báo cáo theo phong cách paper, xây dựng hình và bảng so sánh metrics.

Tài liệu tham khảo

[1] Xubin Ren, Wei Wei, Lianghao Xia, Lixin Su, Suqi Cheng, Junfeng Wang, Dawei Yin, and Chao Huang. Representation Learning with Large Language Models for Recommendation. In *Proceedings of the ACM Web Conference 2024 (WWW '24)*, pages 1–12, Singapore, May 2024. ACM. `https://doi.org/10.1145/3589334.3645458`. arXiv:2310.15950v5.

[2] Simone Colecchia, Mauro Orazio Drago, Jihad Founoun, Paolo Gennaro, Ernesto Natuzzi, Luca Pagano, Sajjad Shaffaf, Giuseppe Vitello, Andrea Pisani, and Maurizio Ferrari Dacrema. From Sequences to Profiles: Generating Universal Behavioral Profiles exploiting Recurrent Neural Networks. In *Proceedings of the RecSys Challenge Workshop at ACM RecSys 2025 (RecSysChallenge '25)*, Prague, Czech Republic, September 2025. ACM. `https://doi.org/10.1145/3758126.3758133`.

[3] Stephen Robertson and Hugo Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond. *Found. Trends Inf. Retr.*, 3(4):333–389, 2009.

[4] Victor Lavrenko and W. Bruce Croft. Relevance-Based Language Models. In *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '01)*, pages 120–127, 2001.

[5] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder, and Li Deng. MS MARCO: A Human Generated Machine Reading Comprehension Dataset. In *Proceedings of the Workshop on Cognitive Computation: Integrating Neural and Symbolic Approaches (CoCo@NIPS 2016)*, 2016.

[6] Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS Datasets and Benchmarks 2021)*, 2021.

[7] Rodrigo Nogueira and Kyunghyun Cho. Passage Re-ranking with BERT. arXiv preprint arXiv:1901.04085, 2019.

[8] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, 2019.

[9] Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. Text Embeddings by Weakly-Supervised Contrastive Pre-training. arXiv preprint arXiv:2212.03533, 2022.

[10] Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. BPR: Bayesian Personalized Ranking from Implicit Feedback. In *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence (UAI '09)*, pages 452–461, 2009.