THU THẬP TIN TỨC QUA RSS ĐỂ PHÂN LOẠI VÀ ĐIỂM TIN TỰ ĐỘNG

Học viên: **Phạm Minh Doanh**
Giảng viên: **TS. Dương Quang Huy**
Học phần: IT4868 - Khai phá Web

Ngày 27 tháng 12 năm 2025

1 Giới thiệu

Sự phát triển mạnh mẽ của các trang báo điện tử khiến lượng tin tức trực tuyến tăng nhanh cả về số lượng lẫn tốc độ cập nhật. Việc theo dõi, tổng hợp và nắm bắt thông tin từ nhiều nguồn khác nhau trở nên khó khăn đối với người dùng cuối.

Trong bối cảnh đó, Web Mining đóng vai trò quan trọng trong việc tự động thu thập, xử lý, phân tích và khai thác tri thức từ dữ liệu web. Đặc biệt với tiếng Việt, các hệ thống tổng hợp tin tức tự động vẫn còn nhiều hạn chế về độ chính xác, khả năng phân loại và tóm tắt nội dung.

Dự án này đề xuất xây dựng một hệ thống Web Mining hoàn chỉnh cho tiếng Việt, tập trung vào ba bài toán chính: thu thập dữ liệu tin tức từ RSS, phân loại chủ đề bằng mô hình học sâu, và điểm tin tự động theo từng khung thời gian.

2 Mục tiêu dự án

Mục tiêu của dự án bao gồm:

- Thu thập tự động tin tức tiếng Việt từ nhiều nguồn RSS khác nhau.
- Làm sạch, chuẩn hóa dữ liệu văn bản thu thập được.
- Phân loại chủ đề tin tức bằng mô hình ngôn ngữ tiền huấn luyện (PhoBERT).
- Tổng hợp và điểm tin tự động theo từng chủ đề trong một khoảng thời gian xác định.
- Xây dựng giao diện trực quan để hiển thị kết quả phân tích.

3 Phạm vi và đối tượng dữ liệu

- Nguồn dữ liệu: RSS từ hơn 20 trang báo điện tử tiếng Việt (VTV, VNExpress, Tuổi Trẻ, Thanh Niên, Dân Trí, ...).

- Dữ liệu gồm: tiêu đề bài viết, mô tả/tóm tắt, thời gian xuất bản, URL và nguồn.
- Phạm vi thời gian: dữ liệu được thu thập liên tục theo chu kỳ (5–10 phút/lần).

4 Kiến trúc tổng thể hệ thống

Hệ thống được thiết kế gồm các thành phần chính:

4.1 Thu thập dữ liệu (Web Crawling)

- Sử dụng RSS feed để thu thập dữ liệu theo chu kỳ.
- Cơ chế tránh trùng lặp dựa trên mã định danh (hash).
- Lưu trữ dữ liệu dưới dạng JSON Lines để thuận tiện xử lý.

4.2 Tiền xử lý dữ liệu

- Làm sạch văn bản (loại bỏ tiền tố nguồn báo, ký tự HTML, nhiễu).
- Chuẩn hóa thời gian xuất bản.
- Kết hợp tiêu đề và tóm tắt làm đầu vào cho các mô hình học máy.

4.3 Phân loại chủ đề

- Sử dụng mô hình PhoBERT đã được fine-tune cho bài toán phân loại chủ đề tin tức.
- Phân loại các bài viết vào các nhóm như: Thời sự, Kinh tế, Thế giới, Giáo dục, Thể thao, ...
- Cơ chế cache kết quả phân loại để tăng tốc hệ thống.

4.4 Điểm tin tự động

- Gom nhóm các bài viết theo chủ đề và khung thời gian.
- Với số lượng bài đủ lớn, hệ thống thực hiện điểm tin tự động bằng mô hình sinh ngôn ngữ (ViT5).
- Trường hợp số lượng bài ít, hiển thị danh sách tin mới nhất thay vì điểm tin.

4.5 Giao diện trực quan

- Xây dựng giao diện bằng Streamlit.
- Cho phép người dùng chọn khung thời gian, xem điểm tin theo chủ đề.
- Hiển thị danh sách bài viết gốc để kiểm chứng kết quả.

5 Công nghệ sử dụng

- Ngôn ngữ: Python
- Thư viện Web Mining: feedparser, requests
- Xử lý dữ liệu: pandas, regex
- Học máy và NLP: PyTorch, HuggingFace Transformers, PhoBERT, ViT5
- Giao diện: Streamlit

6 Ý nghĩa khoa học và thực tiễn

- Ứng dụng trực tiếp các kỹ thuật Web Mining vào bài toán thực tế.
- Kết hợp Web Mining với Deep Learning cho tiếng Việt.
- Hệ thống có khả năng mở rộng để phục vụ tổng hợp tin tức, phân tích dư luận hoặc hỗ trợ báo chí.

7 Kế hoạch thực hiện

- Thiết kế kiến trúc, xây dựng crawler RSS.
- Tiền xử lý dữ liệu và phân loại chủ đề.
- Xây dựng module điểm tin.
- Hoàn thiện giao diện và đánh giá hệ thống.

8 Kết luận

Dự án hướng tới xây dựng một hệ thống Web Mining hoàn chỉnh cho tin tức tiếng Việt, kết hợp thu thập dữ liệu web, khai phá văn bản và học sâu. Kết quả của dự án không chỉ phục vụ mục tiêu học tập mà còn có giá trị ứng dụng thực tiễn cao.