Xây dựng Hệ gợi ý Tin tức dựa trên bộ dữ liệu MIND

Bùi Toàn Thắng – 20251192M
Đỗ Hoàng Long – 20252010M
Nguyễn Thị Ngọc Huyền – 20251330M

Tháng 12 năm 2025

1 Tổng quan

Sự gia tăng nhanh chóng của tin tức trên các nền tảng trực tuyến đã gây ra tình trạng quá tải thông tin, khiến người dùng gặp khó khăn trong việc tiếp cận các nội dung phù hợp với sở thích cá nhân. Hệ gợi ý tin tức ra đời nhằm giải quyết vấn đề này bằng cách phân tích hành vi người dùng và nội dung tin tức để đưa ra các đề xuất phù hợp, góp phần nâng cao trải nghiệm và tiết kiệm thời gian cho người đọc.

Tuy đã có nhiều phương pháp gợi ý tin tức được nghiên cứu, các hệ thống hiện tại vẫn gặp nhiều hạn chế như vấn đề khởi đầu lạnh, khó khăn trong biểu diễn ngữ nghĩa nội dung và khả năng thích ứng với sự thay đổi nhanh của tin tức. Do đó, việc nghiên cứu và xây dựng các hệ gợi ý tin tức hiệu quả, đặc biệt trên các bộ dữ liệu thực tế như MIND, là cần thiết và có ý nghĩa thực tiễn cao trong lĩnh vực Khai phá Web.

2 Cơ sở lý thuyết

Bài toán gợi ý tin tức được đặt trong ngữ cảnh hệ thống sử dụng lịch sử tương tác của người dùng (nhấp chuột, đọc tin) kết hợp với nội dung các bài báo ứng viên để dự đoán khả năng người dùng sẽ quan tâm đến từng tin tức. Mục tiêu là tối ưu hóa mức độ liên quan và tính cá nhân hóa của các gợi ý trong môi trường tin tức có tính thời sự cao và thay đổi nhanh.

Về kiến trúc tổng quát, hầu hết các hệ gợi ý tin tức hiện đại đều tuân theo mô hình ba thành phần chính: Bộ mã hóa tin tức (News Encoder) để biểu diễn nội dung bài báo, Bộ mã hóa người dùng (User Encoder) để mô hình hóa sở thích từ lịch sử đọc tin, và Bộ dự đoán tương tác (Click Predictor) để ước lượng xác suất người dùng tương tác với tin tức ứng viên.

Trong xử lý nội dung tin tức, kỹ thuật nhúng từ (word embedding) đóng vai trò nền tảng, giúp biểu diễn văn bản dưới dạng vector liên tục mang thông tin ngữ nghĩa. Các phương pháp nhúng từ từ truyền thống như Word2Vec, GloVe, FastText đến các mô hình ngữ cảnh như BERT cho phép hệ thống học được mối quan hệ ngữ nghĩa giữa các từ và nội dung tin tức, qua đó cải thiện khả năng so khớp với sở thích người dùng.

Bên cạnh đó, cơ chế chú ý (attention), đặc biệt là chú ý cộng, được sử dụng rộng rãi nhằm giúp mô hình tập trung vào các từ, bài báo hoặc thành phần quan trọng trong lịch sử tương tác của người dùng. Trên nền tảng attention, các kiến trúc học sâu như FastFormer đã được đề xuất để giảm chi phí tính toán so với Transformer truyền thống mà vẫn giữ được khả năng biểu diễn ngữ cảnh hiệu quả.

Nhiều mô hình gợi ý tin tức tiêu biểu đã được phát triển dựa trên các nền tảng lý thuyết này, điển hình là NAML và NRMS [1, 2]. Các mô hình này cho thấy hiệu quả cao trong việc kết hợp nội dung tin tức và hành vi người dùng, đồng thời đặt nền móng cho các hướng tiếp cận hiện đại trong xây dựng hệ gợi ý tin tức.

3 Ý tưởng thực hiện

Các mô hình gợi ý tin tức hiện đại cho thấy hai hướng tiếp cận hiệu quả nhưng còn tồn tại những hạn chế nhất định. Cụ thể, các mô hình dựa trên chú ý đa góc nhìn như NAML khai thác tốt các thuộc tính khác nhau của tin tức (tiêu đề, nội dung, thể loại), tuy nhiên chưa biểu diễn hiệu quả ngữ cảnh sâu của văn bản. Ngược lại, các mô hình dựa trên cơ chế tự chú ý như NRMS có khả năng nắm bắt quan hệ ngữ nghĩa giữa các từ và giữa các tin tức trong lịch sử người dùng, nhưng lại chưa tận dụng đầy đủ các đặc trưng phân loại và thông tin đa thuộc tính của tin tức.

Xuất phát từ những hạn chế đó, ý tưởng thực hiện của đề tài là kết hợp ưu điểm của cả hai hướng tiếp cận: sử dụng các mô hình học ngữ cảnh hiệu quả để mã hóa nội dung và hành vi người dùng, đồng thời tích hợp cơ chế chú ý đa góc nhìn nhằm khai thác đầy đủ thông tin từ nhiều thuộc tính khác

nhau của tin tức. Bên cạnh đó, việc lựa chọn kiến trúc có chi phí tính toán thấp được xem là yếu tố quan trọng nhằm đảm bảo khả năng mở rộng khi áp dụng trên các tập dữ liệu lớn như MIND [3].

Trên cơ sở này, đề tài hướng tới xây dựng một hệ gợi ý tin tức vừa đảm bảo khả năng hiểu ngữ nghĩa và hành vi người dùng, vừa cải thiện hiệu quả tính toán và tính thực tiễn so với các mô hình hiện có.

4 Phương pháp đánh giá

Hệ gợi ý tin tức được đánh giá dựa trên các thước đo phổ biến trong bài toán gợi ý và xếp hạng, bao gồm AUC, MRR và nDCG@K. Các chỉ số này phản ánh khả năng của mô hình trong việc phân biệt tin tức phù hợp với người dùng, đưa các kết quả đúng lên vị trí cao trong danh sách gợi ý, cũng như tối ưu hóa mức độ liên quan tổng thể của danh sách đề xuất.

Bộ dữ liệu được sử dụng trong quá trình đánh giá là MIND (Microsoft News Dataset), một bộ dữ liệu quy mô lớn được xây dựng phục vụ nghiên cứu hệ gợi ý tin tức. MIND bao gồm tập hợp các bài báo với nhiều thuộc tính như tiêu đề, tóm tắt, thể loại và thể loại con, cùng với dữ liệu hành vi người dùng dưới dạng lịch sử nhấp chuột theo từng phiên. Dữ liệu này phản ánh sát các tình huống gợi ý tin tức trong thực tế, nơi hệ thống phải đưa ra quyết định dựa trên chuỗi hành vi ngắn hạn và sự thay đổi nhanh chóng của nội dung tin tức [3].

Trong quá trình đánh giá, mỗi phiên tương tác của người dùng được xem như một truy vấn gợi ý, trong đó mô hình dự đoán xác suất người dùng sẽ nhấp vào các tin tức ứng viên và sắp xếp chúng theo thứ tự giảm dần. Các chỉ số AUC, MRR và nDCG@K được tính toán dựa trên thứ hạng của các tin tức được nhấp chuột trong danh sách dự đoán, nhằm đánh giá chất lượng xếp hạng và khả năng cá nhân hóa của mô hình.

Ngoài việc đánh giá hiệu năng tổng thể, đề tài cũng thực hiện các thí nghiệm so sánh nhằm phân tích ảnh hưởng của một số yếu tố như phương pháp nhúng từ và tham số huấn luyện. Đồng thời, kết quả của mô hình đề xuất sẽ được đối chiếu với một số mô hình gợi ý tin tức tiêu biểu trong các nghiên cứu trước đó, từ đó làm rõ tính hiệu quả và khả năng ứng dụng của hướng tiếp cận được lựa chọn.

5 Kết luận

Đề tài tập trung nghiên cứu bài toán xây dựng hệ gợi ý tin tức trong bối cảnh quá tải thông tin trên các nền tảng trực tuyến, với mục tiêu giúp người dùng tiếp cận hiệu quả hơn các nội dung phù hợp với sở thích cá nhân. Thông qua việc tổng hợp các cơ sở lý thuyết và phân tích những hạn chế của các mô hình gợi ý tin tức hiện có, đề tài định hướng một hướng tiếp cận kết hợp nhằm khai thác đồng thời thông tin ngữ nghĩa của nội dung và hành vi người dùng.

Việc lựa chọn bộ dữ liệu MIND và các thước đo đánh giá chuẩn như AUC, MRR và nDCG@K kỳ vọng sẽ giúp đề tài đánh giá một cách khách quan hiệu quả của hệ gợi ý trong các kịch bản thực tế. Thông qua quá trình thực hiện bài tập lớn, nhóm mong muốn củng cố kiến thức về hệ thống gợi ý, học máy và Khai phá Web, đồng thời hiểu rõ hơn quy trình xây dựng, triển khai và đánh giá một hệ gợi ý tin tức trong thực tiễn.

Tài liệu

[1] Fangzhao Wu, Tao Qi, Jiun-Hung Chen, Chuhan Wu, and Xing Xie. Neural news recommendation with attentive multi-view learning. In *Proceedings of the 28th International Joint Conference on Artificial Intelligence*, pages 3863–3869, 2019.

[2] Fangzhao Wu, Tao Qi, Jiun-Hung Chen, Chuhan Wu, and Xing Xie. Neural news recommendation with multi-head self-attention. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 6389–6394, 2019.

[3] Fangzhao Wu, Ying Qiao, Jiun-Hung Chen, Chuhan Wu, Tao Qi, Jianxun Lian, Danyang Liu, and Xing Xie. Mind: A large-scale dataset for news recommendation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 3597–3606, 2020.